


第2回 モデルの解釈とデータの種類

1. 観光で重要なデータを考えよう
2. できたモデルの解釈の仕方
3. データ分析に使えるツール

長崎大学 情報データ科学部 一藤 裕



● Rを使って時空間データを分析


住宅地価を例に。

イメージしづらければ家賃と考えてもOK

Rを使いこなすために参考となるサイト

フレーム: なし あり

R-tips (<http://cse.naro.affrc.go.jp/takezawa/r-tips/r.html>)
ー基礎からRを学ぶ人におすすめのサイト



統計解析フリーソフト R の備忘録頁 ver.3.1

R は有名な統計言語『S 言語』をオープンソースとして実装し直した統計解析ソフトです。さまざまなプラットフォーム (OS) に対応しており、誰でも自由にダウンロードすることができます。それにも関わらず、世界中の専門家が開発に携わっており、日々新しい手法・アルゴリズムが付け加えられています。とにかく計算が速い上にグラフィックも充実しているので数値計算などにも持ってこいです。このドキュメントは Windows 版 R と Mac OS X 版 R (と一部 Linux 版 R) でコマンドを調べた足跡です。

ちなみに、この頁の内容を新しくした書籍は [こちら](#) , 電子書籍版は [こちら](#) で販売されております。

❁ 入門篇 ❁

リンク	The R Project	リンク	RjpWiki
リンク	PDF版 R-Tips(200頁・3Mb)	索引	この頁の索引
第01節	R のセットアップ+参考文献	第02節	R の起動と終了
第03節	簡単な計算	第04節	R 用エディタ
第05節	オブジェクトと代入 (付値)	第06節	作業ディレクトリの変更
第07節	ヘルプを見る	第08節	パッケージ・ライブラリ
第09節	データの型	第10節	オブジェクトの表示
第11節	オプション		

❁ ベクトル篇 ❁

第12節	ベクトルの作成	第13節	要素へのアクセス
第14節	ベクトルの計算	第15節	ベクトル要素の置換・結合・挿入
第16節	種々のベクトル	第17節	文字列を操作する
第18節	NULL, NA, NaN, Infの操作		

mgcvの特徴

- とても簡単・実用的
- 高速処理
 - 様々な効果を考慮したモデルを100万標本からでも推定可
- 多機能
 - 様々な効果を推定可
 - 場所ごと、時間ごと、非線形、グループ毎の効果などなど
 - 様々なデータが扱える
 - 連続データ、比率データ、カウントデータ、順序データ、多変量データ、サバイバルデータなど

パッケージのインストールとライブラリ読み込み

```
install.packages("mgcv")      ### 初回のみ  
install.packages("mgcViz")  
install.packages("sp")  
install.packages("RColorBrewer")  
Install.packages("car")
```


1回インストールすれば
OK

```
library(mgcv)  
library(mgcViz)  
library(sp)  
library(RColorBrewer)  
library(car)
```

RやRstudioを起動するときには、
1回入力が必要

例) 駅までの距離と住宅地価


駅までの距離と住宅地価の関係を最もよく捉えるには、
どのような線を引けば良いだろう??



例) 駅までの距離と住宅地価

案1: 直線を引く


→あてはまりが悪い



駅までの距離

案2: 全観測点を通るように
線を引く


→複雑すぎて解釈不能



駅までの距離


「あてはまりの良さ」と「なめらかさ」を両立する

- 標本自体ではなく、その背後にある現象を精度よく捉えるように線を引く(関数を見つける)



住宅価格に影響する様々な要因

- ◆ 駅までの距離
- ◆ 景気
- ◆ 地域ブランド などなど



様々な要因を考慮しながら「あてはまりの良さ」と「なめらかさ」を両立するモデルを推定する必要がある

複雑にならないようにする



$$\text{住宅地価} = f(\text{駅までの距離}) + f(\text{景気}) + f(\text{地域ブランド}) + (\text{誤差項})$$



住宅価格に対するあてはまりを良くする

一般化加法モデル

- 様々な**分布**のデータをモデル化可能
- 様々な**要因**(説明変数)の影響をモデル化可能

様々な分布のデータ（被説明変数を扱うことが可能）

被説明変数～確率分布(期待値)

期待値 = $f(\text{説明変数1}) + f(\text{説明変数2}) + \dots + f(\text{説明変数}K)$

各説明変数からの影響を推定

データ分析の流れ

1. 分布の選択

- ✓ 連続データ : 正規分布
- ✓ カウントデータ : ポアソン分布 or 負の二項分布

2. 説明変数の選択

- ✓ **多重共線性**(説明変数の中に相関係数が高い組み合わせがあること)の確認
(多重共線性があると効果の区別がしづらく、何を推定しているかわからなくなる可能性大)

3. 一般加法モデルの適用


- ✓ 各説明変数からの効果タイプを決めて推定
(線形効果or 非線形効果 or 空間可変効果 or,...)

Rを使って実際に動かしてみよう

利用するデータ

多摩都市モノレール線沿線の
住宅地公示地価データ
(1999～2008年)

国土数値情報ダウンロードサ
イト
(<https://nlftp.mlit.go.jp/ksj/>)
のデータを加工



年度	経度	緯度	価格	立川駅 距離	最寄駅 距離	最寄駅 名
year	px	py	y	tachid	ekid	eki_name
1999	139.43363	35.60971	264000	10.0358845	1.96247802	多摩センター
1999	139.42702	35.60976	285000	9.89548659	1.73676662	多摩センター
1999	139.41933	35.61197	279000	9.56034053	0.99441256	唐木田
1999	139.4074	35.61498	300000	9.2324422	0.59201598	唐木田

データの種類と確率分布


データタイプ	例	対応する確率分布
連続データ	気温、住宅地価など	正規分布
カウントデータ	患者数、事故件数など	ポアソン分布、負の二項分布
2値データ	感染の有無など	ベルヌーイ分布

分布の選び方

連続データの場合

→正規分布

- ✓ 平均と分散で形の決まる分布
- ✓ 平均20,分散5の正規分布は $N(20, 5^2)$ と書く



データの種類と確率分布

データタイプ	例	対応する確率分布
連続データ	気温、住宅地価など	正規分布
カウントデータ	患者数、事故件数など	ポアソン分布、負の二項分布
2値データ	感染の有無など	ベルヌーイ分布

分布の選び方


カウントデータの場合

→ ポアソン分布

✓ 0が少ない場合

→ 負の二項分布

✓ 0が多い場合



データの種類と確率分布

データタイプ	例	対応する確率分布
連続データ	気温、住宅地価など	正規分布
カウントデータ	患者数、事故件数など	ポアソン分布、負の二項分布
2値データ	感染の有無など	ベルヌーイ分布

分布の選び方


カウントデータの場合

→ ポアソン分布

✓ 0が少ない場合

→ 負の二項分布

✓ 0が多い場合




データ分析その1：分布の選択


ヒストグラムで被説明変数の分布を確認しましょう
hist関数で図示可能 (hist(dat[, "y"])のように)

- 地価は連続データなので正規分布
 - 被説明変数をできるだけ正規分布に近づけよう
 - 対数変換とか

```
> hist(dat[, "y"])
```



```
> hist(log(dat[, "y"]))
```



対数変換をしたほうが正規分布に近いので、今回は対数変換した地価 $\log(\text{dat}[, \text{"y"}])$ を被説明変数に用いる

データ分析の流れ

1. 分布の選択

- ✓ 連続データ : 正規分布
- ✓ カウントデータ : ポアソン分布 or 負の二項分布

2. 説明変数の選択

- ✓ **多重共線性**(説明変数の中に相関係数が高い組み合わせがあること)の確認
(多重共線性があると効果の区別がしづらく、何を推定しているかわからなくなる可能性大)

3. 一般加法モデルの適用

- ✓ 各説明変数からの効果タイプを決めて推定
(線形効果or 非線形効果 or 空間可変効果 or,...)

Rを使って実際に動かしてみよう

データ分析その2：説明変数の選択

多重共線性

相関の強い説明変数のペアがあると、推定結果が不安定になる。例えば、「駅までの直線距離」と「駅までの道路距離」を同時に説明変数に入れてしまうと、2変数はほぼ同じものを説明するため、どちらからの効果なのかが区別(識別)できなくなる

$$\text{住宅地価} = a + b[\text{駅までの直線距離}] + c[\text{駅までの道路距離}] + (\text{誤差項})$$

↑ ↑
回帰分析では、 b と c を推定することで両説明変数の影響を推定するが、 b と c のうち的一方が大きくなると他方は小さくなってしまうため何を推定しているのかわからない

多重共線性が生じないように説明変数を絞り込む必要あり！！

どうやって?? → Rが解決してくれます

データ分析その2：説明変数の選択

多重共線性の確認方法：VIF (Variance inflation factor)

- VIFが10以上は多重共線性を持つとされる
- 全説明変数のVIFが5以下が理想
(5~10で許容範囲だが、疑いあり)
- Rのパッケージcarのvif関数でVIFが評価可能
- 説明変数のVIFは線形回帰モデルに放り込めば確認可能

Rでの回帰モデルの構文：

被説明変数～説明変数1 + 説明変数2 + . . .

```
> lmod <- lm(log(y) ~ tachid + ekid + year, data = dat) : 線形回帰モデル
> vif(lmod)
      tachid      ekid      year 
1.080331 1.082130 1.001738
```

VIFは10未満(しかもとても小さい)
→ 多重共線性を持っていないことを確認

データ分析の流れ

1. 分布の選択

- ✓ 連続データ : 正規分布
- ✓ カウントデータ : ポアソン分布 or 負の二項分布

2. 説明変数の選択

- ✓ **多重共線性**(説明変数の中に相関係数が高い組み合わせがあること)の確認
(多重共線性があると効果の区別がしづらく、何を推定しているかわからなくなる可能性大)

3. 一般加法モデルの適用

- ✓ 各説明変数からの効果タイプを決めて推定
(線形効果or 非線形効果 or 空間可変効果 or,...)

Rを使って実際に動かしてみよう

一般化加法モデルで考慮できる効果(緑枠はMGCvのRコード)

線形効果


x : 説明変数 x からの線形効果

例: 駅から1km離れる毎に、住宅地価は1万円ずつ下落

非線形効果

$s(x)$: 説明変数 x からの非線形な効果

例: 眺望(x)の
マンション価格
への影響




場所ごとの効果

$te(px, py)$: 残差の空間パターン
 $te(px, py, by=x)$: 回帰係数の空間パターン

例: 人種多様性は
市街地でのみ
犯罪リスクに影響

Cahill and Mulligan (2007)




一般化加法モデルで考慮できる効果(緑枠はMGCVのRコード)

グループごとの効果

`s(group_id, bs="re")`: group_id毎の効果


例: 教育プログラムの
各クラスへの影響



時間ごとの効果

`s(time)` : 残差の時変パターン
`s(time, by = x)`: 回帰係数の時変パターン

例: CO2濃度の
時間変化



MGCVによる線形回帰モデルの推定

$$\log(y) = a + b[\text{tachid}] + c[\text{ekid}] + c[\text{年次}] + \text{誤差項}$$

```
> mod0 <- gam(log(y) ~ tachid + ekid + year, data = dat)
> summary(mod0)
```

Family: gaussian
Link function: identity

Formula:
log(y) ~ tachid + ekid + year

Parametric coefficients:

	Estimate	Std. Error	t value	Pr(> t)	
(Intercept)	83.340156	3.797696	21.95	<2e-16	***
tachid	-0.032136	0.002453	-13.10	<2e-16	***
ekid	-0.213436	0.012853	-16.61	<2e-16	***
year	-0.035288	0.001895	-18.62	<2e-16	***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

R-sq.(adj) = 0.365 Deviance explained = 36.6%
GCV = 0.046822 Scale est. = 0.046706 n = 1613

結果の見方

```
> summary(mod0)
```

$$\log(y) = a + b[\text{tachid}] + c[\text{ekid}] + c[\text{年次}] + \text{誤差項}$$

Family: gaussian

Link function: identity

回帰係数
(a,b,c,d)

Formula:

$\log(y) \sim \text{tachid} + \text{ekid} + \text{year}$

Parametric coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	83.340156	3.797696	21.95	<2e-16 ***
tachid	-0.032136	0.002453	-13.10	<2e-16 ***
ekid	-0.213436	0.012853	-16.61	<2e-16 ***
year	-0.035288	0.001895	-18.62	<2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

R-sq. (adj) = 0.365 Deviance explained = 36.6%

GCV = 0.046822 scale est. = 0.046706 n = 1613

あてはまりの良さ

- 0は最悪、1は最良
- 住宅地価の36.5%を説明

P値: 効果が0である確率

P値が小＝効果あり

- P値が0.05未満: 5%水準で有意(*)
- P値が0.01未満: 1%水準で有意(**)
- P値が0.001未満: 0.1%水準で有意(***)

結果の考察


tachidもekidも0.1%水準で統計的に負に有意

- ✓ 駅から遠いほどと地価が低いという結果は直感に整合
- ✓ 修正済み決定係数(R-sq.(adj))は0.365しかなく、地価変動の36.5%しか説明できなかった

線形回帰モデルでは限界がある

- ✓ 立川駅距離(tachid)の影響は立川駅付近で特に強まる可能性
- ✓ 年次の影響は、景気等の影響で上下している可能性

→非線形の効果を考えてみよう



MGCVで説明変数からの非線形効果を考慮

```
> mod1 <- gam(log(y) ~ s(tachid) + s(ekid) + s(year), data = dat)
> summary(mod1)
```

Family: gaussian
Link function: identity

Formula:
log(y) ~ s(tachid) + s(ekid) + s(year)

Parametric coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	12.288978	0.004306	2854	<2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Approximate significance of smooth terms:

	edf	Ref.df	F	p-value
s(tachid)	8.801	8.987	78.56	<2e-16 ***
s(ekid)	8.497	8.930	88.84	<2e-16 ***
s(year)	4.426	5.451	149.21	<2e-16 ***

edf: 効果(関数)の複雑さ
F値: 説明力

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1


R-sq.(adj) = 0.593 Deviance explained = 59.9%
GCV = 0.030329 Scale est. = 0.029902 n = 1613

→修正済みR2が大幅に改善(0.365 → 0.593)

推定された効果の可視化


```
> mod1 <- gam(log(y) ~ s(tachid) + s(ekid) + s(year), data = dat)
```

```
plot(mod1,select=1)
```




立川駅からの距離が2km以内だと
立川駅に近づくにつれて地価上昇


```
plot(mod1,select=2)
```



```
plot(mod1,select=3)
```



参考：グラフの見方



残された課題：除外変数

立川駅距離、駅距離、年度のみで住宅地価を説明しようとしていた

✓ 非現実的。実際には地価は無数の要因から影響を受けているはず

- モデルから抜け落ちた変数は**除外変数**と呼ばれる


- ✓ 治安, 生活環境, 坂道の多さ, ...

- ✓ 除外変数を無視すると、説明変数からの影響が過大評価されることが知られている...

除外変数への対処

除外変数の影響が空間(相関)パターンを持つと仮定

- ✓ 除外変数の影響が (滑らかな)空間パターンを持つと仮定



地価の場合

除外変数を捉えるための空間パターン項を追加

- ✓ 説明変数からの影響の過大評価を防ぐため
- ✓ 実際には緯度経度の関数

除外変数からの影響(例:上図)を
捉えるための緯度経度の関数



$$\log(y) = a + f[\text{tachid}] + f[\text{ekid}] + f[\text{年次}] + \text{[緯度経度]} + \text{残差}$$

残差の空間パターンも考慮したモデル

```
mod2 <- gam(log(y) ~ s(tachid) + s(ekid) + s(year) + te(px, py), data = dat)
summary(mod2)
```

```
> summary(mod2)
```

```
Family: gaussian
Link function: identity
```

```
Formula:
log(y) ~ s(tachid) + s(ekid) + s(year) + te(px, py)
```

```
Parametric coefficients:
```

```
      Estimate Std. Error t value Pr(>|t|)
(Intercept) 12.288978   0.003373   3643  <2e-16 ***
---
```

```
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
Approximate significance of smooth terms:
```

	edf	Ref.df	F	p-value
s(tachid)	8.959	8.999	40.85	<2e-16 ***
s(ekid)	8.319	8.872	107.32	<2e-16 ***
s(year)	4.846	5.940	226.01	<2e-16 ***
te(px,py)	24.000	24.000	42.73	<2e-16 ***

edf : 効果(関数)の複雑さ
F値 : 説明力

```
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
R-sq.(adj) = 0.75   Deviance explained = 75.8%
GCV = 0.018905   Scale est. = 0.018352   n = 1613
```


残差の空間パターンを捉える
緯度・経度のように2変数以上の場合は
s()関数ではなく、te()関数

推定された空間パターン

```
plot.gamViz(mod2,select=4)
```

立川駅周辺には捉えられていない負の要因(除外変数の影響)が存在

- ✓ 騒音など(?)
- ✓ 空間パターンの導入により、除外変数の影響を間接的に考慮



空間パターンの時間変化まで考慮する場合

- 住宅地価の空間パターンは時間変化している可能性
- 緯度経度に加えて年次も考慮することで、時空間パターンが考慮可


時間パターン
(全域共通の時間変化; 景気等)

時空間パターン
(空間パターンの時間変化)

↓ ↓

$$\log(y) = a + f[\text{tachid}] + f[\text{ekid}] + f[\text{年次}] + [\text{緯度, 経度, 年次}] + \text{残差}$$

住宅地価の時間変化(後述)



時空間パターンを考慮する場合

緯度, 経度, 年次のように2変数以上の場合は
s()関数ではなく、te()関数

```
mod3 <- gam(log(y) ~ s(tachid) + s(ekid) + s(year) + te(px, py, year, d=c(2, 1)), data = dat)
```

```
> summary(mod3)
```

Family: gaussian
Link function: identity

Formula:

```
log(y) ~ s(tachid) + s(ekid) + s(year) + te(px, py, year, d = c(2,  
1))
```

Parametric coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	12.288978	0.003232	3802	<2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Approximate significance of smooth terms:

	edf	Ref.df	F	p-value
s(tachid)	8.815	8.964	33.08	<2e-16 ***
s(ekid)	7.228	8.232	138.84	<2e-16 ***
s(year)	4.940	6.047	77.52	<2e-16 ***
te(px,py,year)	43.891	45.146	28.14	<2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

R-sq.(adj) = 0.771 Deviance explained = 78%
GCV = 0.017565 Scale est. = 0.016848 n = 1613

最初2変数で空間, 最後1つで時間を定義

最良のモデルはどれか

mod0 : $\log(y) = a + b[\text{tachid}] + c[\text{ekid}] + d[\text{年次}] + \text{残差}$

mod1 : $\log(y) = a + f(\text{tachid}) + f(\text{ekid}) + f(\text{年次}) + \text{残差}$

mod2 : $\log(y) = a + f(\text{tachid}) + f(\text{ekid}) + f(\text{年次}) + f(\text{緯度経度}) + \text{残差}$

mod3 : $\log(y) = a + f(\text{tachid}) + f(\text{ekid}) + f(\text{年次}) + f(\text{緯度経度}, \text{年次}) + \text{残差}$

あてはまりとなめらかさを両立する、最良のモデルはどれか

- BIC(またはAIC)を最小にするモデル＝最良モデル

```
> BIC(mod0)
[1] -331.6114
> BIC(mod1)
[1] -931.5364
> BIC(mod2)
[1] -1563.65
> BIC(mod3)
[1] -1582.593
```


mod3が最良！

※ただしmod2も十分良いので
mod2でもよいかも


最良モデル(MOD3)の推定結果: 要約

$$\log(y) = a + f(\text{tachid}) + f(\text{ekid}) + f(\text{年次}) + f(\text{緯度経度, 年次}) + \text{誤差項}$$

立川駅距離(tachid)の影響




駅距離(ekid)の影響



残差の空間パターン
(年次別・除外変数を捉える)


年次の影響




参考：2番目に良いモデル(MOD2)の推定結果

$$\log(y) = a + f(\text{tachid}) + f(\text{ekid}) + f(\text{年次}) + f(\text{緯度経度}) + \text{誤差項}$$


立川駅距離(tachid)の影響




駅距離(ekid)の影響



年次の影響



残差の空間パターン
(全年共通・除外変数を捉える)



演習課題 1

課題

LACSの第2回に広島があります。ダウンロードして、今回の手順を実行して、広島の特徴を確認しレポートを作成してください。レポートには、立川と同じ、mod0～mod3まで作成し、最後に何がどのモデルがよいかをまとめてください。

また、それぞれのsummary結果、非線形のグラフは載せて、どういう特徴かを文章化すること

対象エリア： 広島市

ファイル形式： Word

締め切り： 2025年10月23日（木） 23：59


作成するモデルの非線形グラフを表示するとき

→ y軸の表示範囲を指定していないと横線一本が表示
スケールが合っていないからです。

y軸の表示範囲を限定するコマンド

```
plot(mod2,select=1, ylim=c(-0.2,0.5))
```

y軸が-0.2~0.5の範囲のグラフを表示できます



● 作ったモデルで予測してみよう




地理的要因分析

- ✓ 住宅地価の背後にある様々な要因が定量化できる(済)

時空間補間

- ✓ データの背後にあるパターンをモデル化したことで、データが観測されていない地点・時点のデータが補間(推定)できる

元データ



データの背後にある効果を滑らかな関数で推定したため未観測データの補間が可能

必要となるデータ

◆ 観測地点のデータ

```
> dat[1:5,]  
  year    px    py    y    tachid    ekid    eki_name  
1 1999 139.4336 35.60971 264000 10.035884 1.9624780 多摩センター  
2 1999 139.4270 35.60976 285000  9.895487 1.7367666 多摩センター  
3 1999 139.4193 35.61197 279000  9.560341 0.9944126      唐木田  
4 1999 139.4074 35.61498 300000  9.232442 0.5920160      唐木田  
5 1999 139.4441 35.61717 270000  9.575917 1.4927844      永山
```

◆ 予測地点のデータ

```
> mdat <- read.csv("mdat.csv")  
> head(mdat)  
      px    py    tachid    ekid    eki_name  
1 139.4030 35.76763 7.829623 1.9466561 西武球場前  
2 139.4070 35.76763 7.773742 1.5063260 西武球場前  
3 139.4111 35.76763 7.743632 1.0739068 西武球場前  
4 139.4395 35.76763 8.247735 0.1758087   遊園地西  
5 139.3949 35.76370 7.596492 2.9222489 西武球場前  
6 139.3989 35.76370 7.485007 2.4919205 西武球場前
```

先ほど推定した最良モデル(mod3)を年代を指定して、
時空間補間に応用してみよう

必要となるデータ

◆ 予測地点に年代を追加する

```
> mdat[, "year"] <- 2008
```

```
> mdat[1:10,]
```

	px	py	tachid	ekid	eki_name	year
1	139.4030	35.76763	7.829623	1.9466561	西武球場前	2008
2	139.4070	35.76763	7.773742	1.5063260	西武球場前	2008
3	139.4111	35.76763	7.743632	1.0739068	西武球場前	2008
4	139.4395	35.76763	8.247735	0.1758087	遊園地西	2008
5	139.3949	35.76370	7.596492	2.9222489	西武球場前	2008
6	139.3989	35.76370	7.485007	2.4919205	西武球場前	2008
7	139.4030	35.76370	7.399236	2.0699049	西武球場前	2008
8	139.4070	35.76370	7.340079	1.6625446	西武球場前	2008
9	139.4111	35.76370	7.308182	1.2838660	西武球場前	2008
10	139.4151	35.76370	7.303904	0.9681318	西武球場前	2008

2008のところを変えて再実行すると、その数値に上書きされます

先ほど推定した最良モデル(mod3)を年代を指定して、
時空間補間に応用してみよう

住宅価格の時空間補完(2008年の時)

次のコマンドを入れて予測しよう。
予測はpredict関数を使います。

先ほどの 予測地点
モデル のデータ



```
> pred0 <- predict(mod3, mdat)
> pred0[1:5]
      1      2      3      4      5
11.56630 11.66002 11.71681 12.13816 11.55789
> pred <- data.frame(px=mdat[, "px"], py=mdat[, "py"], pred=pred0)
> pred[1:5,]
      px      py      pred
1 139.4030 35.76763 11.56630
2 139.4070 35.76763 11.66002
3 139.4111 35.76763 11.71681
4 139.4395 35.76763 12.13816
5 139.3949 35.76370 11.55789
```



経度(px),緯度(py),予測値 (pred0)
をデータフレーム(pred)に要約

住宅価格の時空間補完(2008年の時)の結果

経度はpx、緯度はpyと宣言(地理空間データ用の形式に変換するため)



```
> coordinates(pred)<-c("px","py")
```

```
> nc <- 11
```

```
> cuts <- seq(min(log(dat[, "y"])), max(log(dat[, "y"])), len=nc-1)
```

```
> spplot(pred, "pred", cuts=cuts, col="transparent", cex=1.5, pch=15, colorkey=TRUE)
```

色の区切り位置を指定(ncは色の数)



補間値
(pred)で
色分け



色の
区切り
位置

枠線は
消す

各点の
サイズ

各点は
四角

凡例
表示




画面のサイズで、
グリッド線が見え
たり見えなかった
りします。

演習の続き)

時空間補間結果の確認(2000-2008) 立川および広島で実行

- 年次を変えながら、同じコードを繰り返し回し、年代ごとの変化が分かるように並べてみよう



演習課題2

1. 広島ของデータを用いて、同様に2006年～2013年を予測し、26ページのスライドのように時系列変化が分かるように張り付けてください。
2. 時系列変化を見てそこから言えることを自身の言葉でまとめてください。

ファイル形式：PowerPoint

締切：2025年10月29日（木） 23:59